

Parte I: El Corpus OPP-115 y su Ontología Estructural Contexto Histórico y Metodología de Construcción del Corpus El Corpus OPP-115 (Online Privacy Policies, conjunto de 115) representa un hito fundamental en el campo de la privacidad utilizable (Usable Privacy). Fue presentado en la 54ª Conferencia Anual de la Asociación de Lingüística Computacional (ACL) celebrada en Berlín en agosto de 2016, mediante el artículo seminal "The creation and analysis of a website privacy policy corpus" por Shomir Wilson, Florian Schaub, Norman Sadeh, y un equipo multidisciplinario de investigadores. El propósito central de este proyecto era superar de manera decisiva los esfuerzos previos en el campo, los cuales se limitaban a responder preguntas generales simples sobre el contenido de las políticas o analizar métricas superficiales de legibilidad. La metodología de recopilación y estructuración del corpus fue extraordinariamente intensiva, diseñada para garantizar una representación fiel de las prácticas de datos operativas en el internet de consumo. El conjunto consta de 115 políticas de privacidad redactadas en lenguaje natural, obtenidas de sitios web seleccionados mediante los sectores del directorio DMOZ.org y las métricas de tráfico de Amazon Alexa, asegurando así una muestra ecológicamente válida de los servicios digitales. El proceso de anotación manual que dio vida a la taxonomía superó significativamente cualquier esfuerzo previo en NLP legal. Cada una de las 115 políticas fue leída y anotada de forma independiente por tres evaluadores distintos para asegurar la confiabilidad inter-evaluadores (inter-rater reliability). Un total de diez anotadores participaron en el proceso global, todos ellos estudiantes de posgrado en derecho, quienes fueron compensados profesionalmente por su labor. El análisis temporal demostró que estos expertos requirieron un promedio de 72 minutos para procesar cada política individual. Este esfuerzo titánico de comprensión de lectura humana produjo un conjunto de datos masivo con una granularidad sin precedentes. Antes de los procesos de consolidación analítica, los anotadores generaron un total de 23,000 prácticas de datos específicas (data practices), las cuales están interconectadas con 128,000 valores de atributos detallados y enlazadas empíricamente a 103,000 fragmentos de texto seleccionados directamente de los documentos legales (text spans). Para gestionar las redundancias inherentes a tener múltiples evaluadores por documento, los investigadores desarrollaron un método algorítmico de consolidación. Este sistema crea una lista exhaustiva de combinaciones elegibles de prácticas de datos reportadas por los diferentes evaluadores, puntúa y clasifica cada combinación mediante umbrales específicos, priorizando aquellas donde los tres anotadores coinciden antes de descender a los conjuntos donde solo dos coinciden. Este mecanismo de validación cruzada humana solidificó la taxonomía como el estándar de oro en el área. La arquitectura del corpus fue diseñada intencionalmente para ser agnóstica a marcos legislativos particulares

de la época, concentrándose en cambio en los conceptos universales subyacentes a las prácticas de privacidad. Esta decisión de diseño predictivo ha permitido que la taxonomía OPP-115 mantenga su relevancia y sea mapeada directamente a legislaciones modernas y complejas que surgieron posteriormente, como los mandatos de transparencia del Reglamento General de Protección de Datos (GDPR) de la Unión Europea y las estipulaciones de la Ley de Privacidad del Consumidor de California (CCPA). La taxonomía también ha inspirado la creación de corpus derivados, como el MAPP Corpus (Mobile App Privacy Policies), que extendió este marco taxonómico a un conjunto de 155 políticas bilingües (inglés y alemán) enfocadas en aplicaciones móviles.

Arquitectura de Datos: El Grafo Acíclico Dirigido (DAG)

Para comprender cómo los modelos computacionales interpretan la taxonomía OPP-115, es imperativo analizar su estructura de datos fundamental. A diferencia de las ontologías de clasificación tradicionales que emplean jerarquías estrictas en forma de árbol (tree structures), la taxonomía de OPP-115 está organizada matemáticamente como un Grafo Acíclico Dirigido (Directed Acyclic Graph, o DAG). La justificación técnica de esta arquitectura radica en la complejidad de la semántica legal. En un documento de privacidad, un mismo concepto o restricción operativa frecuentemente afecta múltiples esferas de interacción simultáneamente. Bajo una estructura de grafo, los nodos secundarios (los atributos) pueden tener más de un nodo padre (las categorías principales). Por ejemplo, el atributo taxonómico "Tipo de Información Personal" (Personal Information Type) es un vector de datos que es inherentemente relevante tanto para la categoría que describe la recopilación directa por parte del sitio (First Party Collection/Use) como para la categoría que rige la venta o transferencia de datos a corporaciones externas (Third Party Sharing/Collection), e incluso para las cláusulas de seguridad (Data Security). Esta estructura DAG exige que el entrenamiento de modelos de clasificación automatizada de políticas de privacidad se aborde como un problema complejo de clasificación multi-etiqueta (multi-label classification). Los algoritmos diseñados sobre OPP-115, como el clasificador Polisis, deben procesar oraciones y emitir predicciones probabilísticas independientes para cada nodo del grafo, asignando múltiples etiquetas superpuestas a un solo segmento de texto cuando el umbral de probabilidad probabilística (típicamente $P > 0.5$) se supera empíricamente.

Taxonomía de Nivel Superior: Las 10 Categorías Principales

El núcleo del formato esperado para la extracción y etiquetado bajo el estándar de la Universidad Carnegie Mellon divide cualquier texto legal de privacidad en diez categorías principales de alto nivel (High-Level Categories). El dominio de estas diez dimensiones es indispensable para la reconstrucción de bases de datos relacionales orientadas al cumplimiento. A continuación, se presenta el esquema detallado y la casuística de cada categoría.

Categoría Principal (OPP-115 Taxonomy)

Definición Técnica y Alcance

OperativoRelevancia Estadística y Desafíos Computacionales1. First Party Collection/Use (Recopilación y Uso por Primera Parte)Delinea qué información específica recopila el proveedor del servicio directo, el razonamiento subyacente (el por qué) y las metodologías tecnológicas o interactivas empleadas para dicha recolección. Esto abarca desde datos proporcionados voluntariamente (formularios de registro) hasta datos capturados pasivamente mediante telemetría interna o tecnologías de seguimiento propias.Constituye la categoría más densamente poblada en los textos legales corporativos. En conjuntos de validación como PRIVACYQA, esta categoría aborda casi el 41.9% de las interrogantes de los usuarios (ej. "¿qué datos recopila este juego?"). Los modelos modernos (como T5 o GPT-4) alcanzan sus puntajes de precisión F1 más altos en esta categoría debido a la abundancia de datos de entrenamiento.2. Third Party Sharing/Collection (Compartición y Recopilación por Terceros)Regula el flujo exógeno de información. Especifica cómo los datos del usuario son empaquetados, vendidos, alquilados o compartidos con entidades legales distintas al proveedor original. También cubre escenarios donde terceros (como redes de publicidad analítica) insertan rastreadores para recopilar datos directamente desde el entorno del proveedor.Es la segunda área más consultada (24.5%), respondiendo preguntas críticas como "¿se venderán mis datos a anunciantes?". Computacionalmente, es la categoría que históricamente ha generado las mayores tasas de desacuerdo entre anotadores humanos, debido a que las corporaciones utilizan eufemismos legales intencionales ("compartir con socios de confianza") para enmascarar la monetización de datos.3. User Choice/Control (Elección y Control del Usuario)Documenta las opciones de agencia otorgadas a los individuos sobre el ciclo de vida de sus datos. Clasifica las descripciones de mecanismos de control, incluyendo interruptores de inclusión (opt-in) para boletines, enlaces de exclusión (opt-out) para publicidad comportamental, y las rutas administrativas para desactivar o paralizar el procesamiento temporal de información.Abarca el 6.5% de las inquietudes prácticas de los usuarios. Las tareas de NLP a menudo modelan la extracción de esta categoría como un problema binario de clasificación de oraciones para aislar las instancias exactas donde se requiere una acción manual del consumidor.4. User Access, Edit, & Deletion (Acceso, Edición y Eliminación por el Usuario)Categoriza las sentencias que explican si un usuario tiene la facultad operativa de descargar una copia de su información almacenada, corregir registros inexactos que la empresa posea sobre su identidad, o solicitar la destrucción permanente de sus huellas digitales y perfiles asociados.Es una categoría de alto interés regulatorio, ya que mapea directamente hacia los derechos fundamentales garantizados por el Artículo 15 (Derecho de acceso) y el Artículo 17 (Derecho al olvido) del marco GDPR en Europa. Representa el 2.0% de consultas explícitas.5. Data

Retention (Retención de Datos) Rige la temporalidad del almacenamiento. Define las políticas corporativas respecto a cuánto tiempo subsistirá la información en los servidores primarios o bases de respaldo secundarias, y bajo qué justificaciones legales o técnicas se mantiene la data después de que el usuario cesa su relación con la plataforma. Representa aproximadamente el 4.1% de las consultas. Presenta barreras analíticas severas para sistemas extractivos tradicionales; comprender el concepto multidimensional de retención (ej. retención específica de datos financieros por motivos tributarios europeos vs. borrado de datos de ubicación) requiere representaciones lógicas avanzadas a nivel de documento completo (como la arquitectura PolicyLR), superando el simple análisis a nivel de oración.

6. Data Security (Seguridad de Datos) Agrupa los compromisos textuales referentes a la protección de la integridad de los datos. Incluye descripciones de protocolos criptográficos, auditorías, metodologías de almacenamiento seguro y, frecuentemente, cláusulas de exención de responsabilidad donde la corporación advierte que ninguna transmisión en internet es absolutamente infalible. Comprende el 10.5% del interés del consumidor ("¿cómo se protege mi información de los hackers?"). El lenguaje de esta categoría a menudo intercala jerga técnica de ciberseguridad con mecanismos defensivos de limitación de responsabilidad contractual.

7. Policy Change (Cambios en la Política) Aisla el texto que rige la evolución del propio contrato. Determina si los usuarios serán alertados proactivamente sobre enmiendas materiales al texto de privacidad, así como los canales de comunicación obligatorios que el servicio utilizará para efectuar tales notificaciones (ej. correos electrónicos, banners persistentes en la aplicación). Aunque representa solo el 0.2% de preguntas directas, es el eje sobre el cual descansa la validez legal del consentimiento continuo a lo largo de la vida útil de una cuenta de usuario.

8. Do Not Track (No Rastrear) Una categoría altamente especializada que captura las declaraciones sobre si un servicio en línea reconoce, respeta, o ignora explícitamente las señales automatizadas de "Do Not Track" (DNT) transmitidas por los navegadores web diseñadas para bloquear la publicidad conductual en múltiples sitios. Es estadísticamente la categoría menos frecuente en el corpus OPP-115. Paradójicamente, debido al uso de un vocabulario formulaico y restrictivo para abordar este tema, modelos de machine learning tempranos basados en vectores (como SVM) lograron niveles de perfección en su clasificación.

9. International & Specific Audiences (Audiencias Internacionales y Específicas) Recopila exenciones y provisiones normativas que aplican exclusivamente a cohortes demográficas protegidas o jurisdicciones específicas. Los subtemas predominantes abordan la recopilación de datos infantiles bajo normativas como la COPPA (Children's Online Privacy Protection Act), y apéndices de derechos específicos para ciudadanos de California o la Unión Europea. Ha experimentado un crecimiento masivo en

representación en corpus más recientes debido a la fragmentación legislativa ("El Efecto Bruselas"). Los LLMs modernos logran inferir esta categoría mapeando etiquetas hacia los requisitos de la matriz del CCPA.10. Other (Otras Prácticas y Textos Genéricos)Actúa como un receptáculo analítico (catch-all) para secciones introductorias, información de contacto de las autoridades u oficiales de privacidad designados (Privacy Contact Information), definiciones de glosarios y cualquier otra práctica esotérica que escape de los límites estrictos de las nueve dimensiones anteriores.Comprende el 4.8% del interés del usuario. El análisis algorítmico agrupa estas declaraciones en tres subcategorías funcionales: Introductorio/Genérico, Práctica No Cubierta, e Información de Contacto.El "Codebook": Atributos Secundarios y Granularidad ValorativaLa simple clasificación de párrafos en las diez categorías principales no es suficiente para la comprensión automatizada detallada. La innovación crítica de la taxonomía OPP-115 radica en su segundo estrato de anotación, documentado como el "Libro de Códigos" (Codebook). Para cada una de las prácticas de datos categorizadas, el esquema de anotación especifica además un conjunto de "atributos" relevantes junto con diferentes valores posibles predefinidos para estos atributos. En total, el modelo despliega 20 atributos de nivel inferior, cada uno asociado a conjuntos restrictivos de opciones valorativas, lo que permite la reconstrucción de la política en formatos estructurados.Para ilustrar la mecánica y el formato esperado de esta capa de extracción, analicemos la sub-estructura de atributos que rigen las dos categorías operativas más complejas del sistema:Estructura de Atributos para: First Party Collection/UseCuando un modelo identifica que una cláusula legal trata sobre la recopilación directa, la taxonomía exige extraer la siguiente metadata:Atributo: Personal Information Type (Tipo de Información Personal): Mapea semánticamente qué objeto de datos está siendo capturado. Los diccionarios de valores para este atributo son extensos e incluyen entidades como "identificadores de ubicación", "información financiera y de pago", "historial médico", "números de seguridad social", "historial de navegación web", "direcciones IP" y metadatos del dispositivo. En adaptaciones modernas para modelos de lenguaje grande (LLMs), este atributo ha sido expandido para incluir "transcripciones de chat", "salidas generadas por IA" y "retroalimentación del usuario sobre respuestas".Atributo: Purpose (Propósito): El elemento más crucial para auditorías GDPR. Los valores estandarizados especifican si los datos extraídos se destinarán a "Funcionalidades básicas del servicio", "Optimización y análisis", "Personalización de experiencia del usuario", "Marketing y publicidad dirigida", o requerimientos de "Cumplimiento legal".Atributo: Collection Mode (Modo de Recopilación): Clasifica la vía de adquisición en canales provistos activamente por el usuario (ingresados conscientemente en un campo), recopilados de forma automática (rastreadores pasivos) o recibidos de

fuentes externas no relacionadas. Atributo: User Type (Tipo de Usuario): Un atributo opcional que delinea si la práctica afecta exclusivamente a usuarios registrados, visitantes anónimos o clientes comerciales. Estructura de Atributos para: User Choice/Control

Las herramientas de anotación asocian la categoría de opciones del usuario con cinco parámetros de evaluación, cuatro obligatorios y uno opcional :Atributo: Choice Type (Tipo de Elección): Cuantifica la mecánica de control. Los valores dictan si el texto ofrece un "opt-in" (consentimiento previo afirmativo), un "opt-out" (exclusión posterior), un "opt-out link" (enlace tecnológico directo), la opción de "opt-out via contacting company" (exclusión manual vía correo electrónico), o las rutas de gestión de cuentas como "deactivate account" (suspensión) y "delete account" (eliminación total o parcial). Atributo: Choice Scope (Alcance de la Elección): Define qué procesos específicos se paralizan cuando el usuario ejerce su opción de exclusión. Atributos interrelacionados: Tipo de Información Personal y Propósito también se repiten aquí, especificando qué datos exactos se excluyen y de qué actividades de procesamiento específicas. Es importante destacar que durante la construcción del corpus mediante herramientas de software, los anotadores humanos estaban obligados a enlazar un fragmento de texto explícito (text span) como justificación empírica para todos los atributos obligatorios, mientras que los atributos marcados como opcionales o "No especificados" (Unspecified) no requerían selección textual, acomodando así las frecuentes omisiones o ambigüedades en la redacción corporativa. Evolución Computacional: Modelos de Entrenamiento sobre OPP-115 El corpus OPP-115 ha actuado como el campo de pruebas primordial para la evolución del Procesamiento de Lenguaje Natural en el ámbito legal. La trayectoria tecnológica desarrollada utilizando esta taxonomía documenta el rápido progreso de la inteligencia artificial. Las investigaciones originales en 2016 emplearon arquitecturas matemáticas probabilísticas discretas, específicamente Modelos Ocultos de Markov (HMM) emparejados con algoritmos de decodificación de Viterbi, y Máquinas de Vectores de Soporte (SVM). Los experimentos utilizaron validación cruzada quíntuple, dividiendo las 115 políticas en un conjunto de entrenamiento de 75 y un conjunto de prueba de 40. Los resultados demostraron que SVM exhibía una capacidad extraordinaria para predecir textos estandarizados, logrando una precisión perfecta en la etiqueta de "Do Not Track" y un rendimiento sobresaliente en "First Party Collection/Use". La segunda generación de análisis integró redes neuronales recurrentes (LSTM) y arquitecturas como Polisis, que utilizaron clasificadores multietiqueta. El modelo Polisis introdujo la innovación de retornar distribuciones de probabilidad asociadas a cada nodo de la taxonomía. Por ejemplo, al evaluar un párrafo confuso, el sistema extrae las etiquetas

categorizadas donde la confianza algorítmica excede el 50% ($P > 0.5$). Si Polisis predice la categoría first-party-collection-use y en el sub-nodo de propósitos determina los conjuntos {basic-feature, personalization, marketing}, concluye lógicamente que una misma oración describe tres justificaciones distintas simultáneamente. En la era moderna, los Transformers han dominado el paradigma. El ajuste fino (fine-tuning) del modelo base BERT demostró mejoras incrementales en la puntuación F1 y generó sistemas como PrivBERT, que calculan el índice de "perplejidad" (perplexity) de los textos legales. El análisis de perplejidad sobre políticas de compañías top midió cuán impredecible o ofuscado estaba el lenguaje comparado con el modelo lingüístico pre-entrenado. Sin embargo, el paradigma experimental actual indica una superioridad incontestable de los Modelos de Lenguaje Grande (LLMs). Estudios evaluando arquitecturas como GPT-4 y Claude 2 revelan puntajes de Precisión, Exhaustividad (Recall) y métricas F1 significativamente superiores a las generaciones previas (SVM, LSTM, BERT) en la clasificación exhaustiva sobre el espectro completo de OPP-115. A pesar del progreso, persisten desafíos fundamentales ligados a la complejidad humana. Investigaciones recientes evidencian que ignorar los desacuerdos empíricos entre los anotadores originales humanos al entrenar redes neuronales distorsiona la exactitud aparente. El uso empírico de LLMs en conjunción con estrategias matemáticas conscientes del desacuerdo (disagreement-aware approaches) es esencial para manejar la ambigüedad deliberada que los proveedores de servicios inyectan, particularmente en la categoría de compartición con terceros. Para problemas multi-párrafo donde las reglas del GDPR requieren deducciones combinadas de retención, las representaciones lógicas espaciales avanzadas (como PolicyLR) están suplementando los límites de los análisis puramente basados en oraciones.